

Image Captioning, Multi Modal

Image Quality Assessment & Captioning Model

InHun's Multi Modal

Jung Gayeon, Park Sangjun, Park Jayoung, Lee Inhun

The 10th TAVE Conference

DACON, 2023 Samsung AI Challenge: Image Quality Assessment

Contents



Introduction

Methodology

Data Preprocessing

Model Train

Results & Discussion

References

주제 선정 배경





3회차 스터디 서기

[시작]

[종료]

스터디 목차

Chapter6 게이트가 추가된 RNN

Ch 6.1 RNN의 문제점 - 이유진

Ch6.2 기울기 소실과 LSTM - 전준석

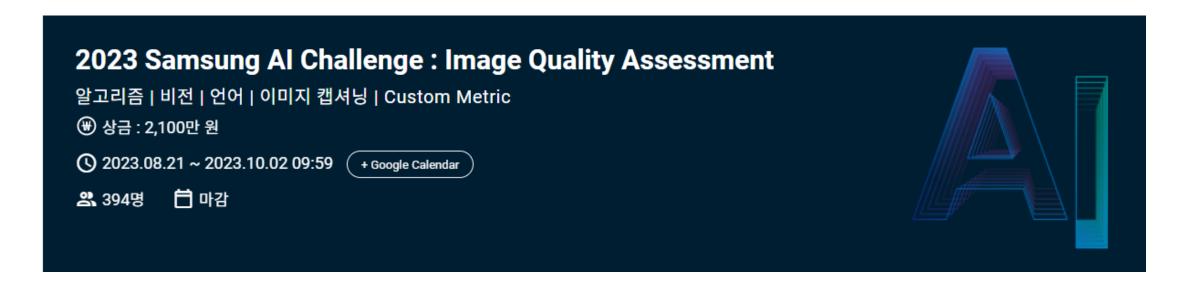
Ch6.3 LSTM구현, Ch6.4 LSTM을 사용한 언어 모델 - 정가연

과제 한단

" Multi Modal "



대회 설명



[주제]

화질 평가 및 Image Captioning

[설명]

카메라 영상 화질 정량 평가 및 자연어 정성 평가를 동시 생성하는 알고리즘 개발 대회

TAVE Technology Wave

Data 소개

	img_name	img_path ~	mos ~	comments
1	41wy7upxzl	./train/41wy7upxzl.jpg	5.56923077	the pink and blue really compliment each other. like the dense color, blur.
2	ygujjq6xxt	./train/ygujjq6xxt.jpg	6.10317460	love rhubarb! great colors!
3	wk321130q0	./train/wk321130q0.jpg	5.54198473	i enjoy the textures and grungy feel to this. i also really like the deep rich red color.
4	w50dp2zjpg	./train/w50dp2zjpg.jpg	6.23484848	i like all the different colours in this pic, the brown, green, dark grey, light grey, cool image.
5	17rqfxeuh0	./train/l7rqfxeuh0.jpg	5.19047619	i love these critters, just wish he was a little sharper, nice comp though.
6	iapcid06sr	./train/iapcid06sr.jpg	5.93846154	excellent use of light. great stuff.
7	twvec6pi41	./train/twvec6pi41.jpg	7.38931298	double trouble! what great detail and curious if you used flash on this.
8	h0wh5in2rd	./train/h0wh5in2rd.jpg	6.12307692	is this really meters from you? how lucky can you get. theyre so fuzzy!
9	j70kuiwf5y	./train/j70kuiwf5y.jpg	6.86614173	i generally dont like overprocessed images, but somehow it works here. very painterly, david hockneylike quality.
10	9qls7ros2m	./train/9qls7ros2m.jpg	5.75396825	awesome tones. great mood. beautiful stuff.

• img_name: 이미지 파일명

• img_path:이미지 경로

mos : 화질 평가 점수 (0~10, float)

• comments : 인지 화질 평가 내용을 캡셔닝한 정보

[train Data]

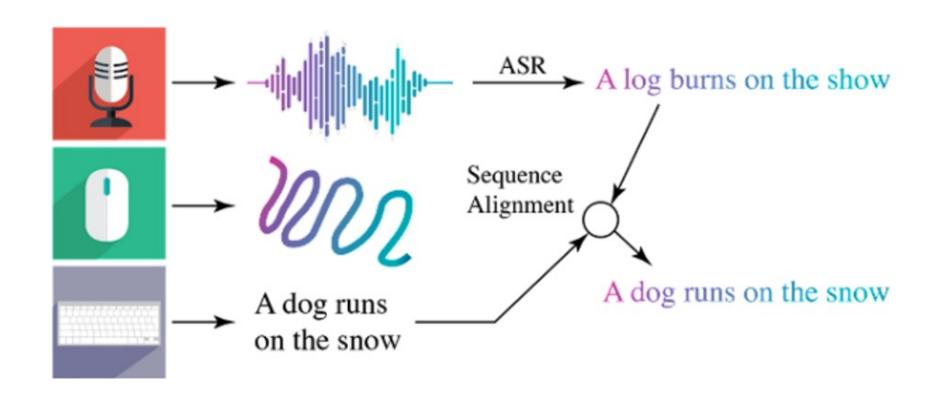
74,568 개

[Test Data]

13,012 개



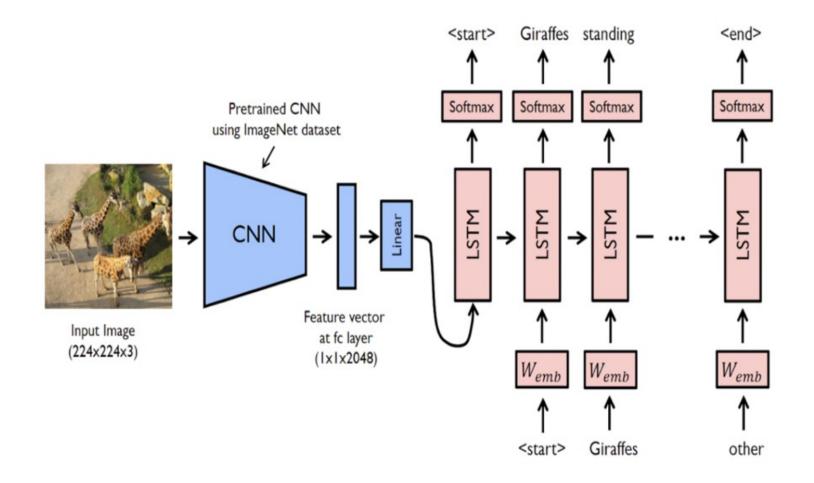
Multi Modal



" 서로 다른 특성을 갖는 Data Type 들을 함께 사용하는 학습법 "

TAVE Technology Wave

Image Captioning



" 주어진 Image에 대한 Caption을 예측하는 작업 "

ResNet + LSTM



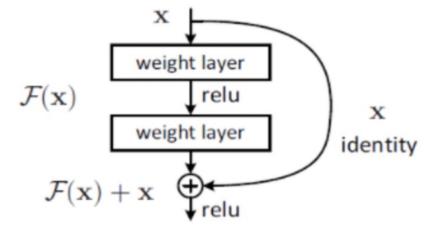
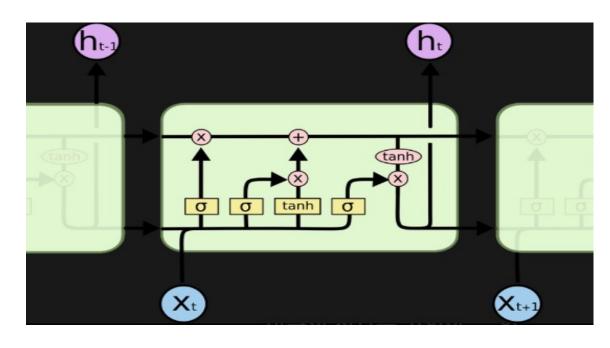


Figure 2. Residual learning: a building block.

[ResNet]

Residual Block 구조가 쌓여 만들어진 모델.
overfitting, gradient vanishing 문제를 해결하여
성능을 향상시킨 모델



[LSTM]

기존 RNN 모델에 cell-state가 추가된 구조

3개의 Gate를 통해 메모리 값을 균일하게 유지하면서
꼭 필요한 만큼의 정보를 기억하는 모델

MobileNet, GoogLeNet



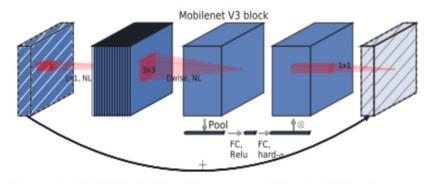


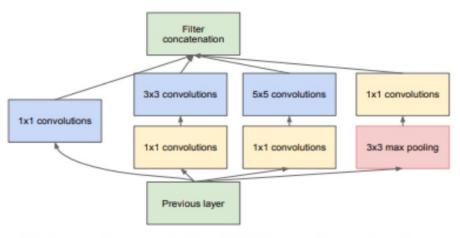
Figure 4. MobileNetV2 + Squeeze-and-Excite [20]. In contrast with [20] we apply the squeeze and excite in the residual layer. We use different nonlinearity depending on the layer, see section 5.2 for details.

[MobileNet]

Depthwise Separable Convolution 이용

연산량이 크게 늘지 않으면서 성능 개선

: 모바일과 같은 작은 규모에서도 사용 용이



(b) Inception module with dimension reductions

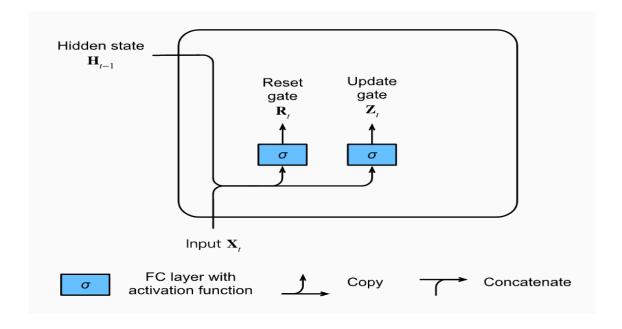
[GoogLeNet]

Inception Module(1x1 Convolution 활용)을 통한 연산량 감소 및 성능 개선

GRU







[GRU]

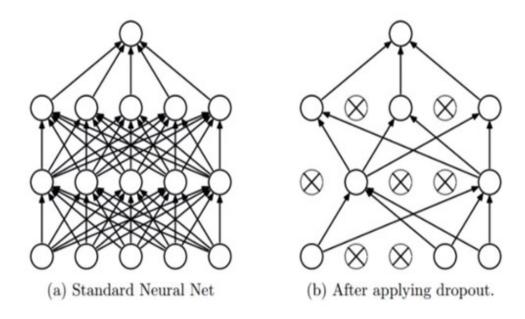
LSTM의 단점을 개선한 모델

두 개의 Gate로 효율적 계산

빠른 학습, 낮은 계산 복잡성 가짐

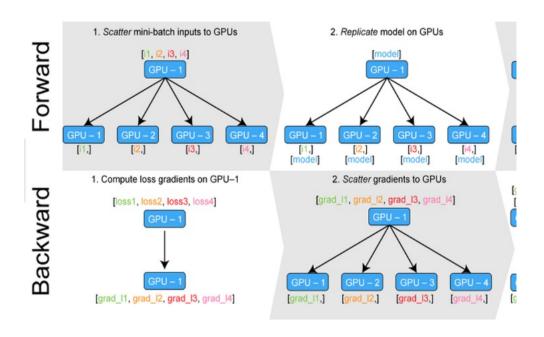
TAVE Technology Wave

Drop-out, Data parallelism



[Drop-out]

Regularization의 일종 Layer에서 각각 독립적인 unit을 **일정 비율에 맞춰 삭제**하는 기법



[Data parallelism]

다수의 GPU를 병렬적으로 활용하는 기법 학습 속도 개선 효과

Data Preprocessing

Color&Gray, Image Size



```
transform = transforms.Compose([
    transforms.Resize((CFG['IMG_SIZE'], CFG['IMG_SIZE'])),
    transforms.Grayscale(), # 흑백 변환 추가
    transforms.ToTensor()
])
```

! Fail!

comments

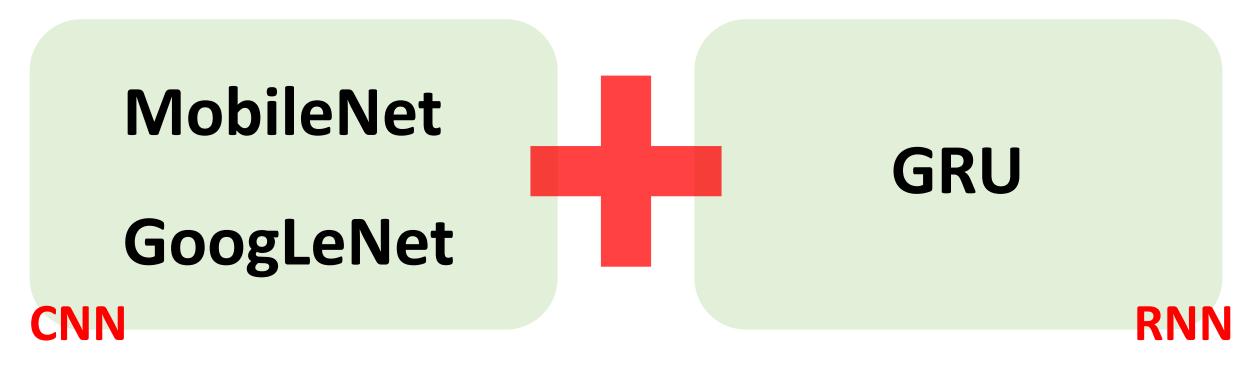
```
CFG = {
   'IMG_SIZE': 128, # 224
   'EPOCHS': 5,
   'LR': 0.01,
   'BATCH_SIZE' : 32, #64
   'SEED': 41
}
```

224 → **128**

Technology Wave 12th 12 The Control of the Contro

Model Train





Learning rate: 0.01

Epochs: 10

Batch Size: 32

64 **→** 32



모델 점수 비교

	Public Score	Private Score
ResNet + LSTM (224)	0.200708494	0.190623514
MoblieNet + GRU + Dropout	0.200708494	0.190623514
MoblieNet + GRU + Dropout + Parallel	0.200708494	0.190623514
GoogLeNet + GRU + Dropout + Parallel	0.199509431	0.190258485

Technology Wave 12th





	1 epoch 당 평균 소요 시간	전체 학습 시간
ResNet + LSTM (224)	17분	3시간
MoblieNet + GRU + Dropout	13분 50초	2시간 30분
MoblieNet + GRU + Dropout + Parallel	13분 40초	2시간 30분
GoogLeNet + GRU + Dropout + Parallel	14분 20초	2시간 35분

정확한 값이 아닌 대략적인 수치임을 알려드립니다.



한계 및 개선방향

[한계점]

1. GPU 자원의 한계

: 다른 SoTA 모델 다뤄보지 못함

: 추가 실험 진행 불가

2. 모델 성능 < 모델 경량화

: 성능보다 경량화에 비중을 맞춘 진행

(모델 선택, 이미지 크기 등)

[개선방향]

1. 파라미터 조정

: 각 모델에 따라 최적의 파라미터 값 서치

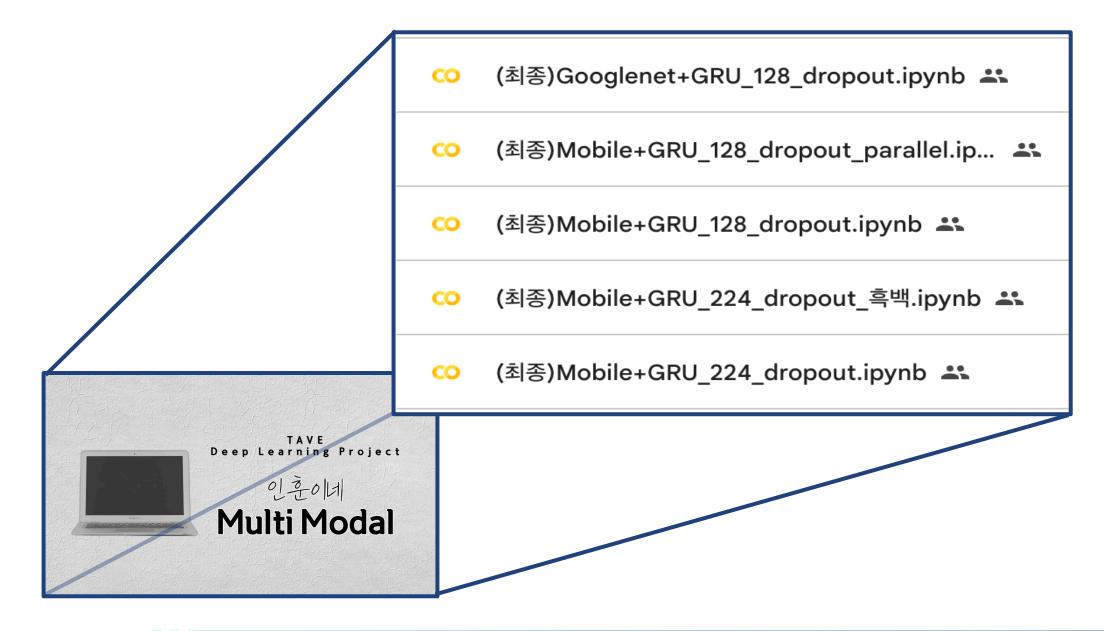
2. 모델 이분화

: 화질 평가와 Captioning 모델 분리

Technology Wave 12th



의의



Technology Wave 12th

References



- 1. Karpathy, A., & Fei-Fei, L. (2015). Deep visual-semantic alignments for generating image descriptions. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 3128-3137).
- 2. Mao, J., Xu, W., Yang, Y., Wang, J., Huang, Z., & Yuille, A. (2014). Deep captioning with multimodal recurrent neural networks (m-rnn). arXiv preprint arXiv:1412.6632.
- 3. Vinyals, O., Toshev, A., Bengio, S., & Erhan, D. (2015). Show and tell: A neural image caption generator. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 3156-3164).
- 4. ResNet 구조 이해 및 구현, https://wjunsea.tistory.com/99
- 5. RNN과 LSTM을 이해해보자!, https://ratsgo.github.io/natural language processing/2017/03/09/rnnlstm/
- 6. PyTorch Multi-GPU 제대로 학습하기, https://medium.com/daangn/pytorch-multi-gpu-학습-제대로-하기-27270617936b
- 7. Multi-modal Learning, https://velog.io/@ysw2946/9.-Multi-modal-Learning
- 8. Image-Quality-assessment, https://github.com/kjae0/image-quality-assessment
- 9. MobileNet V3 논문 리뷰, https://velog.io/@pre-f-86/MobileNet-V3-%EB%85%BC%EB%AC%B8-%EB%A6%AC%EB%B7%B0
- 10. Gated Recurrent Units (GRU), https://d2l.ai/chapter_recurrent-modern/gru.html

Technology Wave 12th 12 The Control of the Contro